DATA ANALYSIS REPORT

# 用户增长与留存及渠道投入效率分析

## 基于访问订单与营销费用日志的实证分析

分析工具

MySQL · Python · Excel

数据来源

Y.Afisha 公开用户行为与营销数据集（GitHub）

报告日期

2026.10

作者：朱韵妍 | GitHub：https://github.com/Juunyeon/user_growth_analysis

# 第一章 项目概述

## 1.1 业务背景与分析目标

本项目围绕用户从首次访问到购买及后续回访的过程，联合访问日志、订单日志和渠道费用，分析获客规模、用户活跃、回访留存及营销投入效率。分析期为 2017 年 6 月 1 日至 2018 年 5 月 31 日，形成 MySQL 提取、Python 分析和 Excel 交互展示的完整流程。

第一，明确新增用户、活跃与留存的变化，区分用户规模扩张和持续使用。第二，按首访同期群及生命周期识别不同阶段的用户。第三，衡量首次访问到首次购买的转化，并对渠道规模、收入 LTV 和获客成本进行一致口径比较。第四，将发现转为可验证的业务建议，保留数据限制和实验验证条件。

## 1.2 核心业务问题与主要结论

本项目重点回答三个相互衔接的问题：用户规模与活跃如何变化，首访后的回访和生命周期状态如何，以及用户购买与渠道投入能否形成可比较的收入回报。

观察期共有 228,169 名访客，其中 36,522 人发生购买，转化率为 16.01%。新增访客在 2017 年 11 月达到峰值，此后总体回落；严格次日回访留存为 2.58%。已记录收入低于营销费用，整体 ROAS 为 0.766，需优先审查获客结构并验证用户价值，而不能将预算扩大等同于有效增长。

| 核心指标 | 结果 | 解释 |
| --- | --- | --- |
| 访客 / 购买用户 | 228,169 / 36,522 | 观察期唯一uid |
| 有效订单 / 访问 | 50,414 / 359,400 | 订单排除1条跨期记录 |
| 购买转化率 | 16.01% | 首访后观察期内购买 |
| D1 / D7 / D30 | 2.58% / 0.65% / 0.25% | 各自成熟分母 |
| ROAS | 0.766 | 收入 / 已记录营销费用 |

表 1-1

本报告的结论为历史数据描述和归因比较。尚未实施营销实验或上线优化，不将建议写成已实现的增长效果。

# 第二章 数据来源与分析方法

## 2.1 数据来源与分析范围

本项目采用公开的 Y.Afisha 用户行为与营销数据集，通过 GitHub 公开仓库获取原始 CSV 文件。数据包括用户访问日志（visits_log_us.csv）、订单日志（orders_log_us.csv）和营销费用记录（costs_us.csv），分别用于分析用户活跃与留存、购买转化及渠道投入效率。

原始数据共包含 359,400 条访问记录、50,415 条订单记录及 2,542 条营销费用记录。分析时间范围为 2017 年 6 月 1 日至 2018 年 5 月 31 日，采用左闭右开的时间区间，即包含 2017 年 6 月 1 日，不包含 2018 年 6 月 1 日。

数据获取地址：

https://github.com/edaletsadigov/online-store-business-analysis/tree/main/dataset

本项目基于公开数据独立完成数据清洗、指标计算、可视化分析及业务建议。由于数据未明确提供可核验的原始发布说明、金额币种和时区信息，报告沿用原始金额与时间字段，不对未知信息作额外假设。

| 数据表 | 原始行数 | 关键字段及用途 |
| --- | --- | --- |
| visits_log_us | 359,400 | Uid、Start Ts、End Ts、Source Id、Device；访问和首访识别 |
| orders_log_us | 50,415 | Uid、Buy Ts、Revenue；首购、订单及收入 |
| costs_us | 2,542 | source_id、dt、costs；渠道日期费用 |

表 2-1

## 2.2 数据预处理与质量检查

使用独立数据库 user_growth_portfolio 保留原始表。用户 ID 以 VARCHAR 和 Python 字符串处理，避免超出整数范围及浮点数精度损失。先使用 ROW_NUMBER 按用户及访问时间确定首访，再分别聚合访问和订单，最后进行用户级关联；不直接连接两张用户一对多明细表，以防收入被访问次数放大。

首访渠道以观察期第一次访问的 Source Id 确定，设备同步保留。若时间并列，则依次使用渠道、设备及原始行号排序。本数据未发现同一用户同时间多渠道的并列组。订单收入归属用户的首访渠道，不按购买当日访问渠道重新分配。

| 检查项目 | 结果 | 处理方式 |
| --- | --- | --- |
| 缺失 / 完全重复 | 均为0 | 保留原始表并审计 |
| 会话结束早于开始 | 2条 | 仅将时长置空，保留有效开始时间 |
| 订单超出统一窗口 | 1条，收入3.42 | 单独记录并排除 |
| 无访问匹配 / 早于首访订单 | 均为0 | 关联及时间顺序通过 |
| SQL与Python逐用户核验 | 6项通过 | 首访、渠道、首购、订单及收入等 |
| 其他数据一致性检查 | 6项通过 | 新增合计、活跃大小关系等 |
| 独立SQL指标复核 | 9项通过 | 末日活跃及三组留存分子分母 |

表 2-2

另发现 2018-03-31 只有 1 名活跃用户，2018-04-01 没有访问记录。现有数据无法区分业务异常和采集缺口，主分析按记录保留，另排除首访日或回访目标日位于这两日的同期群进行敏感性对照。对照 D1、D7、D30 分别为 2.58%、0.65%、0.25%，与主结果接近，仍不能据此排除采集问题。

渠道 6 和 7 无费用记录；其余渠道也存在部分日期缺行。费用总额只代表已记录金额，无法判定缺行属于零投放还是漏记。缺少费用时不填 0，CAC 和 ROAS 保持不可用。

## 2.3 指标定义与计算口径

访问按开始时间归属日期，不拆分跨夜会话。首次访问仅指观察期内首次出现，存在左截断，不能直接等同注册新增或真实新客。原始订单没有业务订单 ID，导入行号只是记录键，不能据“无完全重复行”证明不存在业务重复订单。

| 指标 | 计算口径 |
| --- | --- |
| 日 / 月新增 | 观察期MIN(start_ts)归属日期或月份的唯一用户 |
| DAU / WAU / MAU | 当天 / 含当天7日 / 含当天30日有访问的唯一用户 |
| 自然月MAU与黏性 | 自然月唯一访客；月内平均DAU / 自然月MAU |
| D1 / D7 / D30留存 | 首访后严格第N自然日回访人数 / 已观察至目标日的首访用户 |
| 月度Cohort | 首访月用户在第M自然月访问人数 / 该首访月用户，M0=100% |
| 固定窗口购买转化 | [首访时间,首访+N×24小时)内购买人数 / 完整观察该窗口的用户 |
| 访客 / 购买CAC | 对应渠道已记录费用 / 首访用户或购买用户 |
| 收入LTV与ROAS | 收入 / 用户；收入 / 营销费用。均不是利润指标 |

未到观察截止日的回访目标日不能当作未留存，因此各留存天数使用各自成熟分母。按月份汇总时以回访人数和成熟人数分别求和后相除，不对每日百分比直接平均。自然月 MAU 不能逐月求和解释为全年用户数。

观察期转化和累计 LTV 随首访时间改变而拥有不同观察时长。固定 30 日 LTV 仅对整月所有用户均满 30 日的首访月份展示，本数据为 2017 年 6 月至 2018 年 4 月。30 日同期群 ROAS 将这些用户首访后 30 日收入与同首访月份渠道费用对齐，是描述性费用匹配，不是用户级真实广告回报。

以每个月末为快照，当前 30 天首访的活跃用户为新访客；当前和之前 30 天均访问的非新用户为持续活跃；更早首访、前窗未访问但当前访问者为回流；已知用户中当前窗口无访问者为沉默。四类互斥且覆盖全部已知用户，前窗口不足月份单独标记。

## 2.4 分析工具与技术流程

MySQL 负责建表、导入、窗口排序、聚合关联和 CSV 提取；Python 负责空值与异常检查、日期和用户去重、指标计算、SVG 及 PNG 图表、notebook 和审计文件；Excel 用公式及原生图表组织交互展示。各阶段保留脚本，源数据、计数、比率与展示层分开管理。

# 第三章 用户增长与活跃分析

## 3.1 新增用户规模与增长趋势

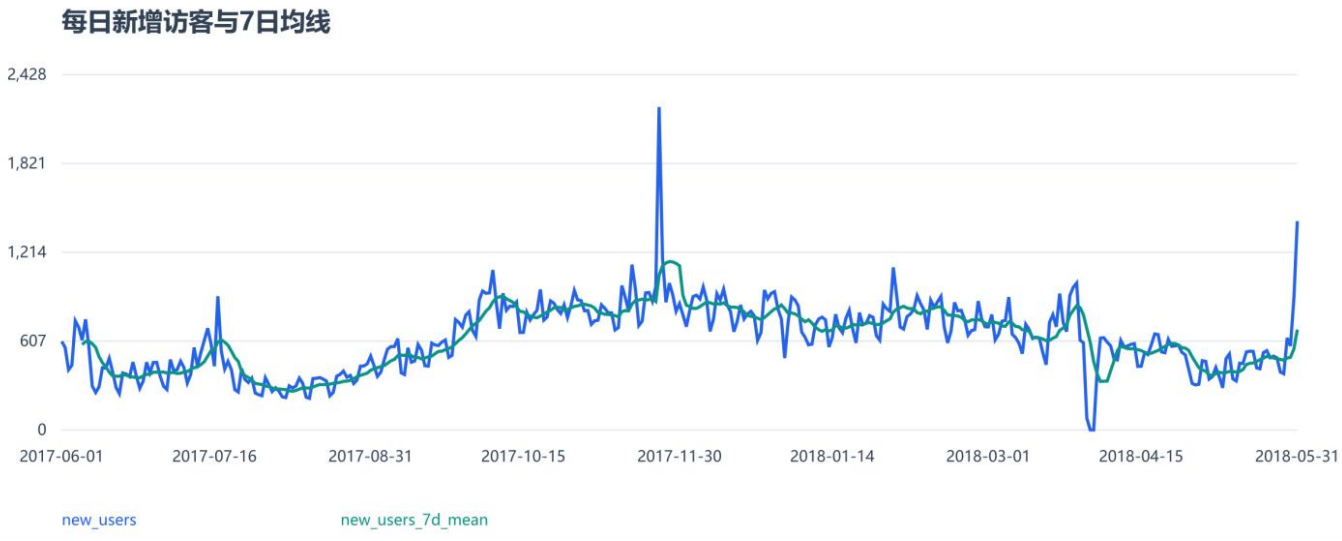



图 3-1 每日首访用户及 7 日均线

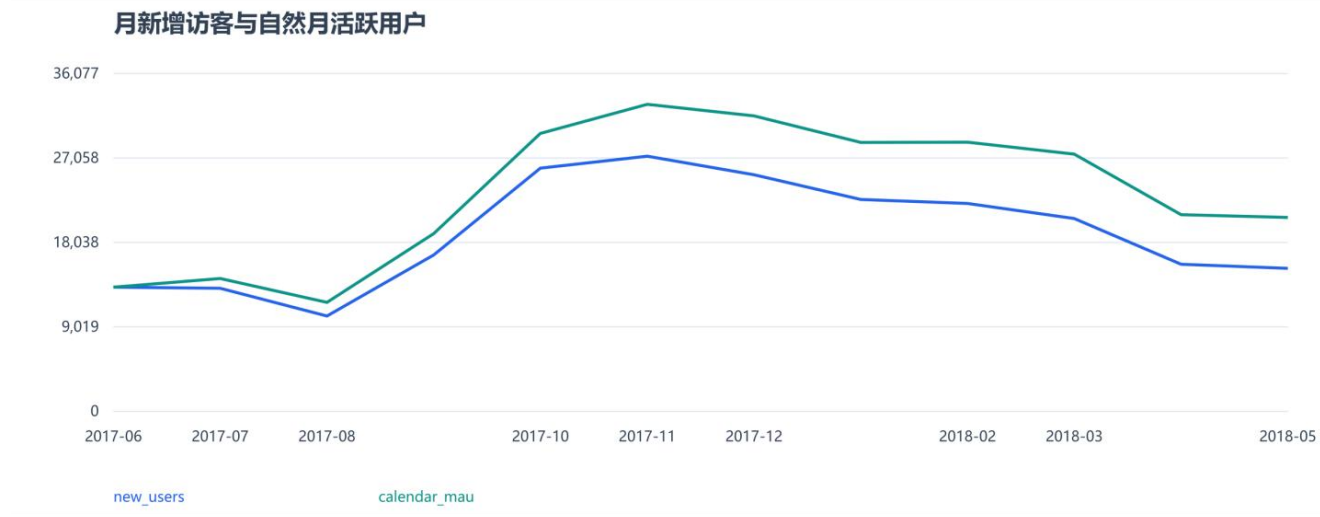



图3-2 每月首访用户与自然月活跃用户

2017 年 11 月新增 27,248 人，为观察期峰值；2018 年 5 月新增 15,273 人，较峰值下降 43.9%。9 月与 10 月的新增环比分别约 64.1%和 55.5%，显示增长主要集中于秋季。该模式只有一年的记录，不能直接推断季节性，也不能归因为某次营销活动。

新增与自然月活跃趋势接近，提示新增规模对活跃总量影响较大；是否因留存不足导致后续回落，还需结合渠道构成、费用和完整采集日志进一步拆解。

## 3.2 用户活跃规模与黏性分析

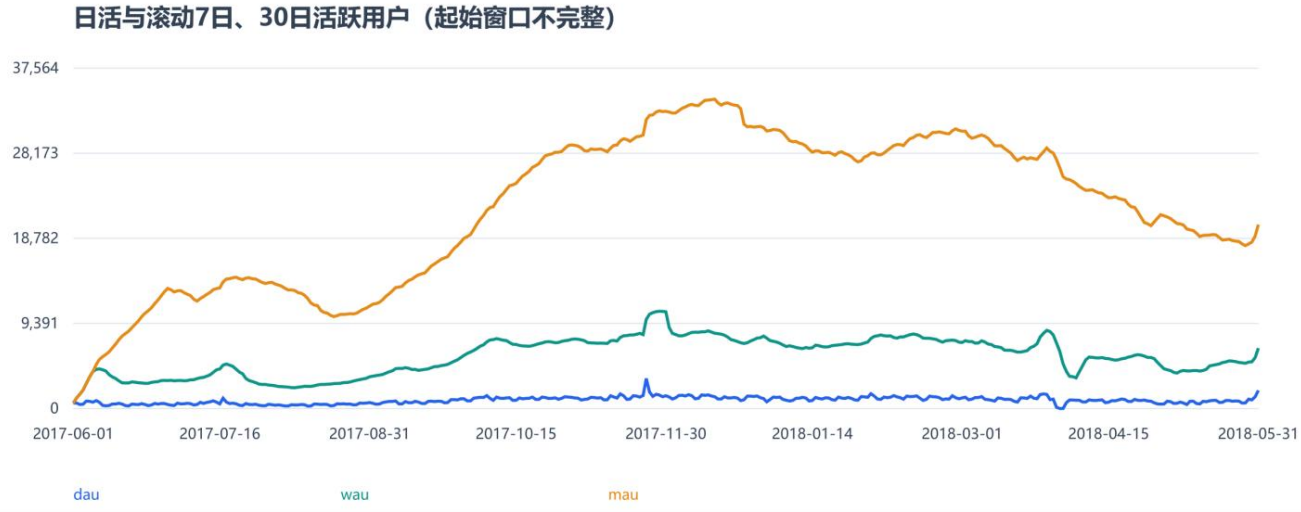



图3-3 DAU及滚动WAU MAU

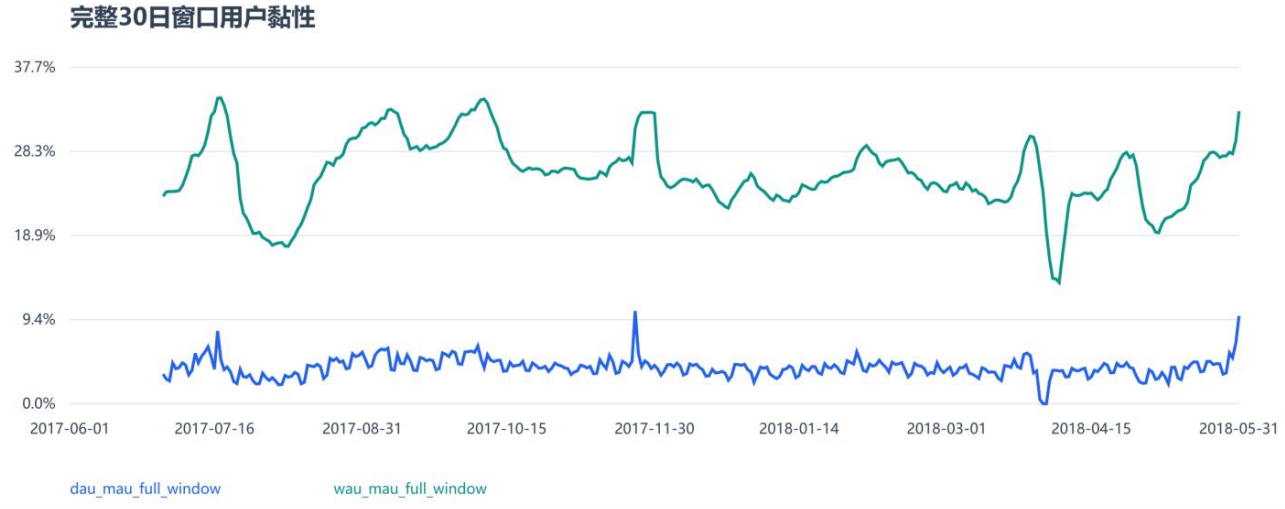



图3-4 完整30日窗口的活跃黏性

日均 DAU 为 906 人；完整窗口平均 WAU 为 5,808 人，平均 MAU 为 23,316 人。日均 DAU/MAU 为 4.06%，描述月活用户在某一天的活跃覆盖程度，不等同人均访问频次。

起始 7 日和 30 日窗口不完整，计算长期平均时排除相应初始日期。2018 年 3 月底与 4 月初的明显低谷包含异常低流量日期，不能将其直接解释为运营失败或用户流失。

## 3.3 用户增长与活跃表现小结

新增用户和自然月活跃在 2017 年秋季同步上升，随后回落，说明用户规模的变化需要同时从获客与持续访问两方面观察。较低的日活覆盖率提示访问频率有限，但不能仅凭活跃曲线判断用户价值。下一步应结合相同观察窗口内的留存与购买表现，区分新增规模变化、用户质量差异和采集异常的影响。

# 第四章 用户留存与生命周期分析

## 4.1 次日、7 日、30 日留存分析

| 目标日 | 成熟首访用户 | 回访人数 | 留存率 |
|---|---|---|---|
| D1 | 226,742 | 5,853 | 2.58% |
| D7 | 223,367 | 1,445 | 0.65% |
| D30 | 213,204 | 536 | 0.25% |

表 4-1

严格第 N 日回访率较低，但不能据此直接断定产品整体使用价值低。访问场景可能具有低频特征，也可能存在跨设备识别限制。首访后 7 天内任意一次回访与严格第 7 天回访是不同指标，本项目使用后者。

## 4.2 Cohort 同期群留存分析

月度同期群访问留存（空白为未观察）

| | M0 | M1 | M2 | M3 | M4 | M5 | M6 | M7 | M8 | M9 | M10 | M11 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 2017-06 | 100.0% | 7.9% | 5.4% | 6.1% | 6.9% | 7.1% | 6.1% | 5.8% | 5.2% | 5.1% | 4.1% | 4.5% |
| 2017-07 | 100.0% | 5.6% | 5.1% | 5.6% | 5.8% | 4.8% | 4.5% | 4.6% | 3.9% | 2.9% | 2.7% | — |
| 2017-08 | 100.0% | 7.7% | 6.3% | 6.3% | 5.0% | 4.4% | 3.6% | 3.9% | 2.8% | 2.6% | — | — |
| 2017-09 | 100.0% | 8.5% | 6.9% | 5.1% | 3.9% | 3.8% | 3.6% | 2.4% | 2.3% | — | — | — |
| 2017-10 | 100.0% | 7.9% | 5.2% | 3.9% | 3.4% | 3.2% | 2.1% | 2.0% | — | — | — | — |
| 2017-11 | 100.0% | 7.8% | 4.4% | 3.9% | 3.4% | 2.3% | 2.2% | — | — | — | — | — |
| 2017-12 | 100.0% | 5.6% | 3.8% | 3.1% | 2.0% | 1.9% | — | — | — | — | — | — |
| 2018-01 | 100.0% | 6.0% | 3.9% | 2.5% | 2.0% | — | — | — | — | — | — | — |
| 2018-02 | 100.0% | 5.7% | 2.5% | 2.0% | — | — | — | — | — | — | — | — |
| 2018-03 | 100.0% | 4.2% | 2.7% | — | — | — | — | — | — | — | — | — |
| 2018-04 | 100.0% | 4.8% | — | — | — | — | — | — | — | — | — | — |
| 2018-05 | 100.0% | — | — | — | — | — | — | — | — | — | — | — |

图4-1 首访月份用户在后续月份的访问留存

2017 年 6 月同期群在 M1 的月访问留存约 7.9%，M11 约 4.5%；2018 年 4 月同期群的 M1 约 4.8%。月留存表示当月至少一次访问，与日留存不应直接比较。新同期群可观察月份更少，矩阵右上空白代表未观察，而不是零留存。

应在相同月龄比较不同同期群，结合获客渠道结构及固定窗口转化判断用户质量；现有观察不能识别留存差异的因果来源。

## 4.3 用户生命周期分群分析

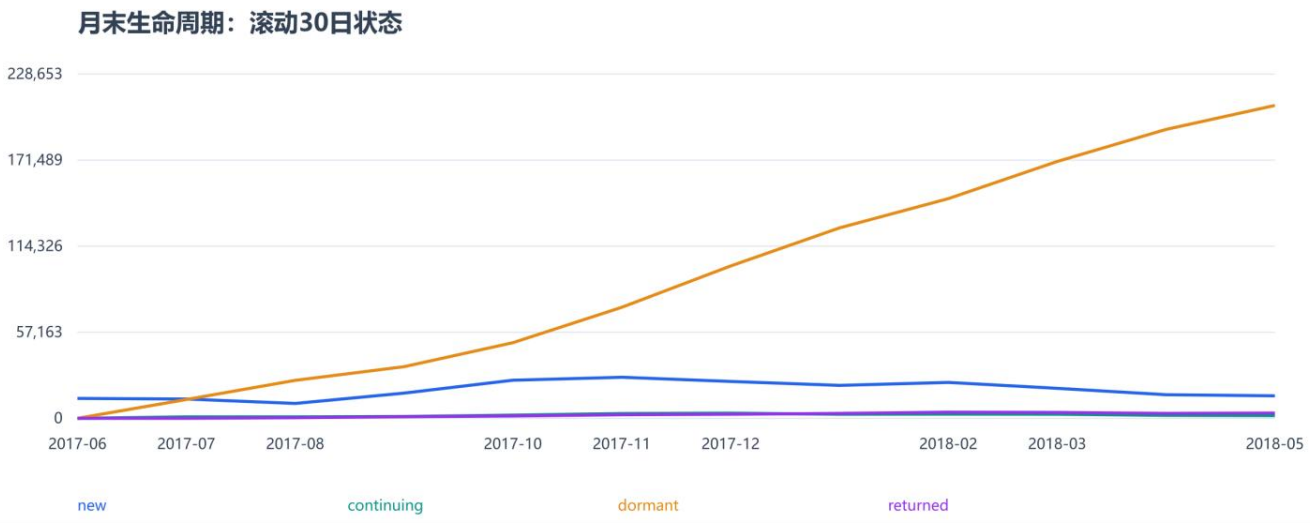



图4-2 月末滚动30日生命周期用户规模

| 2018年5月末状态 | 用户数 | 占已知用户 |
|---|---|---|
| 新访客 | 14,965 | 6.56% |
| 持续活跃 | 1,813 | 0.79% |
| 沉默 | 207,866 | 91.10% |
| 回流 | 3,525 | 1.54% |

表 4-2

5 月末当前滚动窗口为 5 月 2 日至 5 月 31 日，因此新访客 14,965 人与自然月新增 15,273 人不同。沉默为历史已知用户的存量，随历史用户累计而上升；沉默占比不等同某月流失率，也不能直接作为触达名单规模。

回流用户 3,525 人说明有更早访问者重新出现，但本数据没有触达事件，不能将回流归因于营销。可先按沉默时长和首购情况分层，在可触达且合规的人群中开展随机对照实验，验证增量回访与增量购买。

## 4.4 用户留存与生命周期小结

严格日留存与月度同期群分别反映特定日期回访和较长周期使用，生命周期分群则补充沉默与回流的状态视角。三类结果共同说明，后续运营应区分新访客、持续访问者及历史沉默用户，并采用统一观察窗口评估。异常日期、身份识别和左截断仍会限制解释，回流也不能直接归因于营销触达。

# 第五章 用户转化与渠道投入效率分析

## 5.1 首次访问到购买转化分析




图5-1 整月成熟首访用户的固定窗口购买转化

观察期内购买用户 36,522 人，整体转化率 16.01%。该比例包含不同长度的用户观察期，因此跨首访月份比较时应优先采用固定 1 日、7 日、30 日窗口，而不是直接比较累计转化。

| 首访月份 | 1日转化 | 7日转化 | 30日转化 |
|---|---|---|---|
| 2017-06 | 13.61% | 14.87% | 16.03% |
| 2017-11 | 10.52% | 11.95% | 13.31% |
| 2018-02 | 11.18% | 12.50% | 13.49% |
| 2018-04 | 9.91% | 11.00% | 11.74% |

表 5-1

成功购买者从首访至首购的时长中位数约 16 分钟，说明已转化用户的首单行为较为集中。该统计只覆盖成功购买者，不能说明全部用户会在短时间内购买，也不能用于估算未购买者转化时间。

可围绕首次访问当天的路径提出首购实验，但当前数据没有页面浏览、加购、结算和优惠曝光，无法定位具体漏斗步骤。补充事件后应先确认埋点覆盖，再按随机分组检验首日购买率及 30 日收入，避免仅优化点击等代理指标。

## 5.2 渠道规模与购买转化表现

| 渠道 | 首访用户 | 购买用户 | 转化率 | 购买CAC | 观测ROAS |
|---|---|---|---|---|---|
| 1 | 9,469 | 2,899 | 30.62% | 7.19 | 1.492 |
| 2 | 17,616 | 3,506 | 19.90% | 12.21 | 1.096 |
| 3 | 66,116 | 10,473 | 15.84% | 13.49 | 0.386 |
| 4 | 72,346 | 10,295 | 14.23% | 5.93 | 0.928 |
| 5 | 49,237 | 6,931 | 14.08% | 7.47 | 1.017 |
| 6 | 2 | 0 | 0.00% | 缺少费用 | 不可用 |
| 7 | 32 | 1 | 3.12% | 缺少费用 | 不可用 |
| 9 | 6,448 | 1,088 | 16.87% | 5.07 | 1.044 |
| 10 | 6,903 | 1,329 | 19.25% | 4.38 | 0.764 |

表 5-2

渠道 4、3、5 是首访用户规模最大的三个渠道；渠道 1 的观察期转化率约 30.62%，高于主要规模渠道。转化率高不必然代表增量价值高，仍需同时考虑获客费用、购买金额和观察时长。渠道 6 和 7 样本极少，且缺少费用，不适合据此排名或扩大投放。

## 5.3 用户获取成本与收入 LTV 分析

已记录收入为 252,053.78，营销费用为 329,131.62。每首访用户 CAC 为 1.44，每购买用户 CAC 为 9.01；观察期每访客收入 LTV 为 1.10，每购买用户收入 LTV 为 6.90。

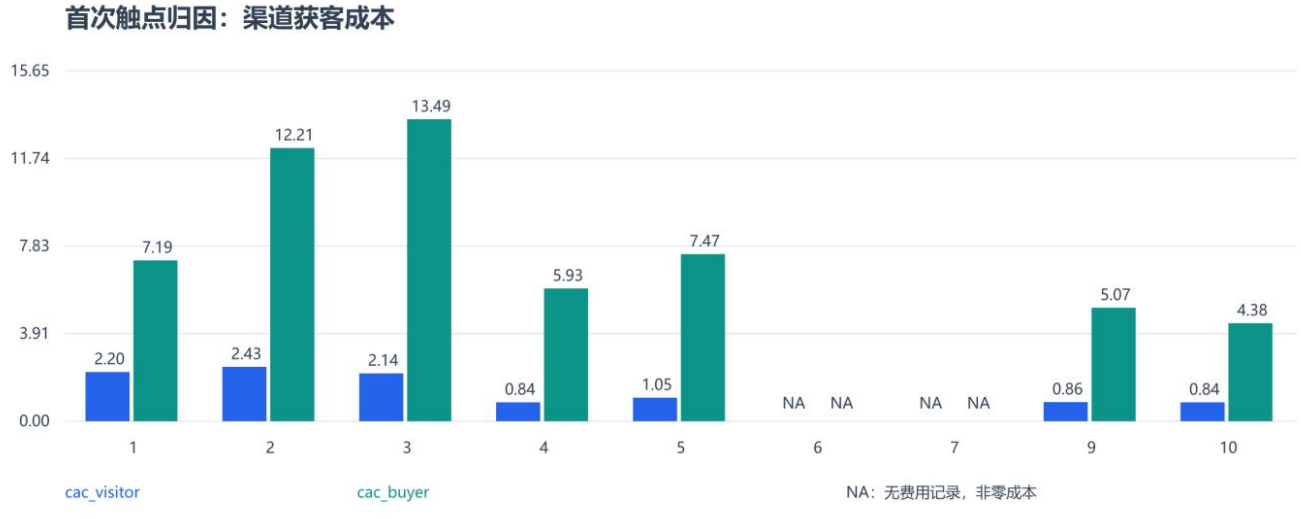


图5-2 首访渠道的每访客及每购买用户获客成本

| 渠道 | 成熟用户数 | 30日LTV每访客 | 30日ROAS |
|---|---|---|---|
| 1 | 8,737 | 1.653 | 0.746 |
| 2 | 16,071 | 1.194 | 0.478 |
| 3 | 62,280 | 0.623 | 0.294 |
| 4 | 67,068 | 0.562 | 0.663 |
| 5 | 46,265 | 0.634 | 0.610 |
| 6 | 2 | 0.000 | 不可用 |
| 7 | 30 | 0.041 | 不可用 |
| 9 | 6,134 | 0.423 | 0.504 |
| 10 | 6,309 | 0.536 | 0.624 |

表 5-3

固定 30 日比较仅汇总 2017 年 6 月至 2018 年 4 月整月成熟同期群。渠道 1、4、10 的 30 日 ROAS 分别约 0.746、0.663、0.624；所有有费用记录渠道的 30 日收入均未覆盖同期首访月份费用。该结果并不等同于完整终身回报，也不能用于宣布渠道利润亏损。

## 5.4 渠道 ROAS 与预算审查优先级

渠道 3 使用约 42.9%的已记录费用，只贡献约 21.6%的观察期归因收入，其观测 ROAS 为 0.386、固定 30 日 ROAS 为 0.294，应优先检查渠道内活动、人群、创意与落地页构成。建议在补齐投放信息后进行受控预算实验，不直接将累计归因结果等同因果效果。

利润 ROI 无法计算，因为缺少毛利、退款、履约和完整运营成本。收入减营销费的差额率只描述两项金额之间的关系；预测终身价值还需要更长观察期及可验证的外推模型。

# 第六章 综合结论与业务建议

## 6.1 核心分析结论

本项目呈现的核心问题是获客规模与后续用户价值尚未形成稳定闭环。新增和活跃在阶段性高点后回落，回访与持续活跃有限；首购行为较集中，但累计转化与收入受观察时长影响。渠道之间的规模、成本和固定窗口回报差异进一步表明，优化重点应从单纯扩大流量转向评估获客质量、首购路径和后续价值，并用增量实验验证预算与运营调整。

## 6.2 用户增长与转化优化建议

将首日未购买者按设备、首访渠道、访问时段及会话行为进一步分层。补齐页面和结算事件后，对落地页或首购引导进行随机实验，比较首日和 7 日购买转化；同时观察 30 日收入、退款和体验指标，防止短期优惠透支后续价值。

对有购买历史和仅访问未购买的沉默用户分别提出召回假设。先核实可触达性并配置不触达对照组，衡量新增回访、增量购买及触达成本。回流用户自然发生，只有实验才能判断召回是否有效。

## 6.3 渠道投入优化与实验验证方案

先对渠道 3 的投放活动及人群结构做分解，补充曝光、点击、转化成本及广告计划信息，判断低回报集中在哪些活动。预算实验保持总预算和观察期可比较，以增量购买及固定 30 日贡献为主要结果，不以归因收入变化替代增量效果。

| 验证方向 | 主要指标 | 执行前需补充 |
| --- | --- | --- |
| 渠道预算结构 | 固定30日增量收入及成本 | 活动、曝光、点击及实验分组 |
| 首访购买路径 | 1日与7日购买转化 | 页面、加购、结算事件 |
| 沉默用户召回 | 增量回访及增量购买 | 触达记录、对照组、退订情况 |
| 收益评估 | 贡献利润及利润ROI | 毛利、退款、履约及运营成本 |

表 6-1

上述均为待验证方案。实验周期与样本量需根据基线、最小可检测效应和检验功效确定，不能预设“留存提升”或“ROI 提高”作为已实现结果。

# 第七章 分析局限性与项目交付

## 7.1 数据与分析局限性

数据仅覆盖一年，首访和用户生命周期存在左截断；用户的长期价值尚未完全观察。异常低流量日期及费用缺行可能影响规模与效率。访问身份依赖原始 uid，无法验证跨设备、跨浏览器识别。渠道 ID 没有业务名称，不能将某数字渠道直接标注为搜索、社媒或自然流量。

订单仅有时间、收入和用户，不包含商品、退款、订单状态及毛利。购买指标将零收入订单也视为购买记录；收入不代表利润。多个渠道用户的人群与使用动机存在差异，历史归因不能控制这些混杂因素。

## 7.2 项目成果与可复现说明

| 成果 | 主要内容 |
| --- | --- |
| SQL脚本 | 01导入、02关联提取、03质量核验、04独立指标复核 |
| Python脚本与notebook | 清理、指标、图表、实际执行输出及质量断言 |
| 数据与审计文件 | MySQL提取、清理明细、指标CSV、原始与提取文件哈希 |
| Excel Dashboard | 月份和渠道筛选、原生图表、公式、同期群热力矩阵及明细 |
| 本报告 | 业务问题、数据口径、八个模块发现、建议与验证边界 |

表 7-1

复现顺序为 MySQL 导入及提取、Python 分析及质量检查、Excel 重建和报告更新。12 项数据一致性检查与 9 项独立 SQL 复核均通过；跨期订单、异常时长、留存敏感性及费用缺失已分别保留记录。

工作簿采用与前一项目一致的浅蓝标题、指标卡和趋势图布局，提供首访月份与首次触点渠道下拉筛选。总览展示同期群规模、购买、收入、费用和回访留存，其他分析页分别承载全量活跃、同期群矩阵、生命周期、固定窗口转化和渠道效率。

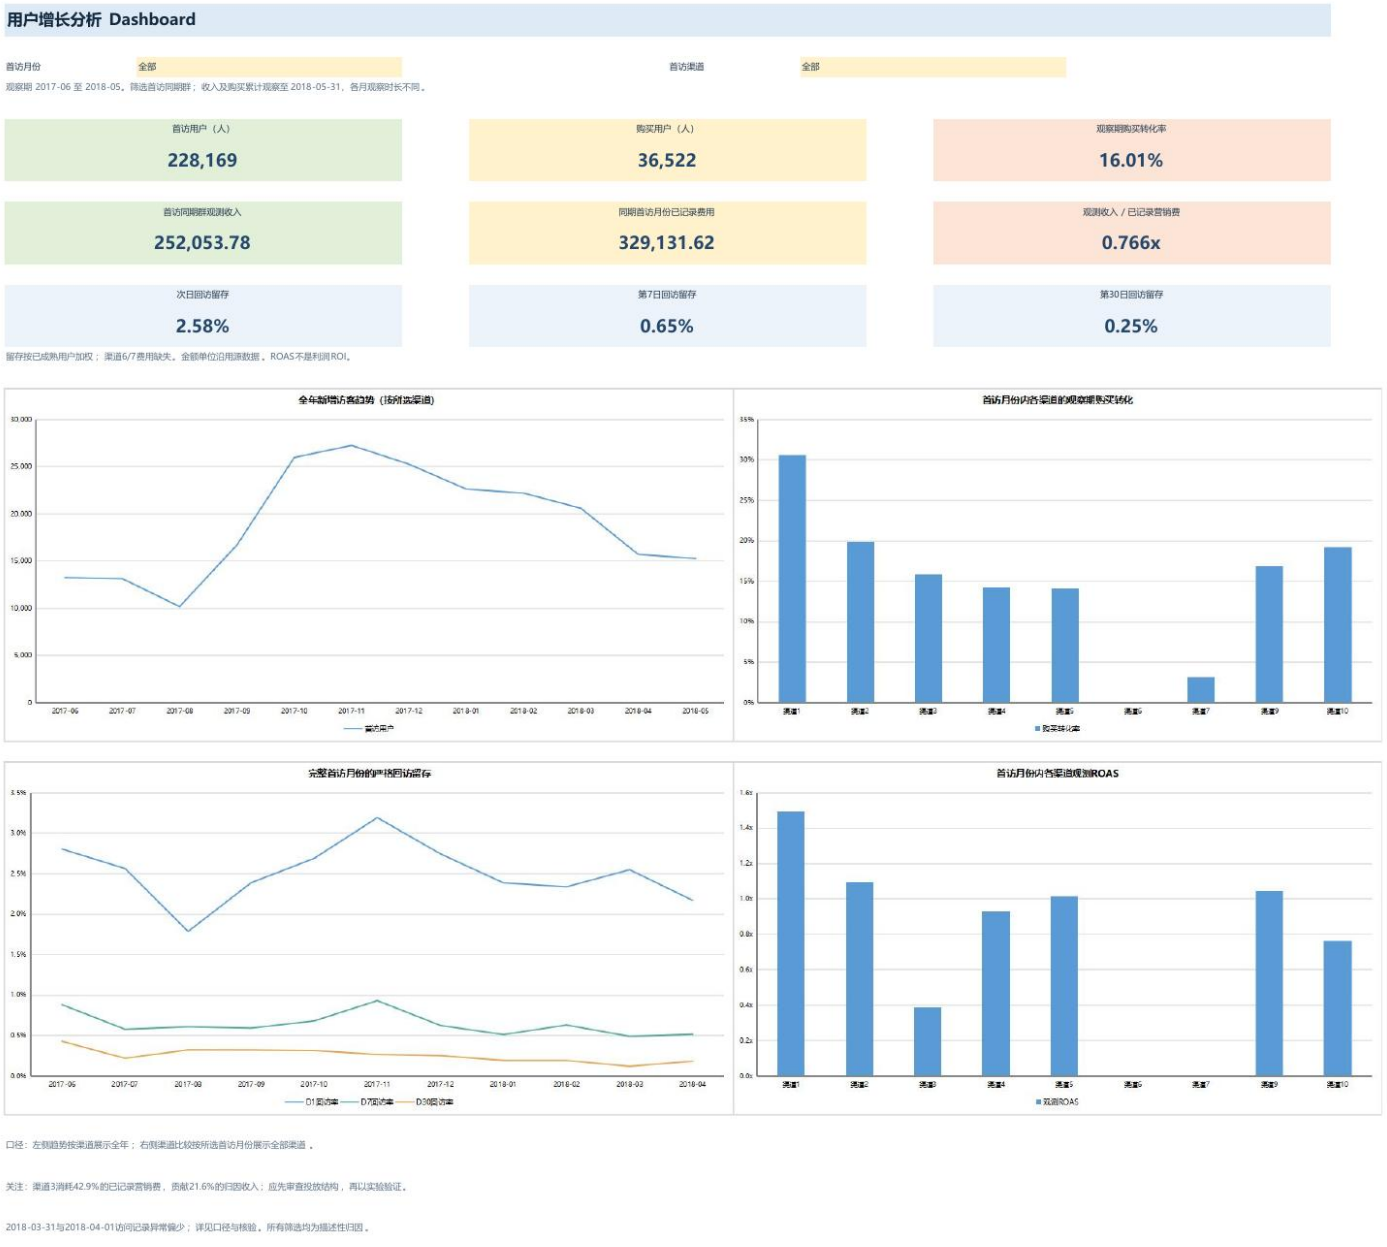



图 7-1 用户增长分析 Excel 总览

数据页保留 Python 核验后的计数、成熟分母和金额，Excel 以 SUMIFS、比例及联动公式形成展示；图表为可编辑原生图表。首访月份筛选影响同期群指标，全年趋势按渠道展示；全量活跃页不受同期群筛选影响。

## 7.3 后续研究方向

优先补充采集状态和费用缺行说明，确认基线数据完整性；再补充投放活动、用户路径及贡献利润数据，构建从广告触达到购买及长期价值的闭环。将本项目作为可复核的分析基础，在实验验证后评估具体业务效果。